

分类号: _____

单位代码: _____

学 号: _____

浙江大学

博士学位论文读书报告



中文论文题目: 卷积神经网络

英文论文题目: Convolutional neural networks

姓名: 罗浩

导师: 姜伟

专业: 控制科学与工程

学号: 11532034

学院: 控制学院

报告日期 2016年1月

摘 要

卷积神经网络(Convolution neural networks, CNN)是一种由传统的神经网络(Neural networks, NN)发展而来的深度学习方法。传统的神经网络随着网络层数的增加,参数量与计算量会急剧增加,由于计算机计算能力的限制制约了传统神经网络的发展。更重要的是随着层数的增加,神经网络在反向传播是会出现梯度消失(Gradient vanish)的现象,导致网络无法训练。

卷积神经网络通过局部连接、权值共享和池化采样三个步骤,解决了传统神经网络参数量巨大,无法训练的问题。这也使得卷积神经网络可以从原始数据中直接提取特征进行模式识别任务,取代了传统的人工提取特征加上训练分类器的模式。本篇读书报告将从卷积神经网络的这三个特性切入,分析卷积神经网络作为新一代机器学习技术的有效性。

关键词: 卷积神经网络, 神经网络, 局部连接, 权值共享, 池化采样

目 次

摘要	I
目次	
1 传统神经网络的瓶颈.....	1
1.1 神经网络的数学原理	1
1.2 神经网络的瓶颈	3
2 卷积神经网络.....	5
2.1 局部连接	5
2.2 参数共享	6
2.3 池化采样	7
3 卷积神经网络进行图像识别.....	9
3.1 卷积神经网络的优点	9
3.2 卷积神经网络识别图像实例	9
参考文献	11

1 传统神经网络的瓶颈

卷积神经网络的前身是神经网络(Neural networks, NN)，为了介绍卷积神经网络，我们先介绍神经网络的数学原理并以此引出神经网络的缺陷瓶颈。

1.1 神经网络的数学原理

神经网络(Neural networks, NN)是一种典型的机器学习方法，是现代卷积神经网络的基础前身。神经网络的基础单元为神经元，其为仿造人脑的神经元细胞所设计，在学术界也称作感知机，结构图如图1所示。每一个神经元有若干个输入，用 $X = [x_1, x_2, x_3, \dots, x_i]^T$ 表示，对于输入 x_i 有一个权重系数 w_i ，表示为 $W = [w_1, w_2, w_3, \dots, w_i]$ ，另外加一个常数偏置 b ，之后通过一个非线性的激活函数 f ，最后的输出写作：

$$y = f(\sum w_i x_i + b) = f(WX + b) \quad (1-1)$$

若干个这样的神经元全连接起来，便可以得到一个多层感知机(Multi-layer Perceptron, MLP)，也叫做多层神经网络。在多层神经网络中，第一层叫做输入层(input layer)，最后一层叫做输出层(output layer)，中间的都叫做隐层(hidden layer)，图2是一个单隐层神经网络的例子示意。从输入到输出的过程是把数值从低层传向高层，这个过程叫做前馈传播。两层神经元之间都有一条线连接，这条线代表着这两个神经元之间的权重系数。单隐层单输出的神经网络拓展到更一般的形式，有权重系数 $w_{ij}^{(l)}$ ，其中 l 代表第 l 到 $l+1$ 层， i 代表第 $l+1$ 的第 i 个神经元， j 代表第 l 的第 j 个神经元，另外 $b^{(l)}$ 表示第 l 到 $l+1$ 层的偏置。最后前馈传播的公式可以表示为：

$$a_i^{(l+1)} = f(z_i^{(l+1)}) = f(\sum w_{ij}^{(l)} a_j^{(l)} + b^{(l)}) \quad (1-2)$$

利用这个传播公式，神经网络就可以从输入 x 得到输出的值，之后利用反向传播算法(back propagation, BP)^[1]训练得到最优的参数及 (W, b) 。BP算法是一种基于梯度下降的优化方法，基本原理有点像下山，我们的目标是找到目标函数的最小值。目标函数的分布曲面就好像一个山脉，我们想要去山脉的最低点。最简单的做法就是沿着下山的方向不停走，梯度下

降法就是基于这种原理，函数的梯度方向的反方向就是下山最快的方向，所以只要求出函数的梯度，我们就可以渐渐向函数的最小值逼近。假设给神经网络输入一个 x ，便可以得到一个预测值 $h_{W,b}(x)$ ，我们定义一个损失函数：

$$J(W, b, x, y) = \frac{1}{2} \|y - h_{W,b}(x)\|^2 = \frac{1}{2} \|y - a^{(l+1)}\|^2 = \frac{1}{2} \|y - f(z_i^{(l+1)})\|^2 \quad (1-3)$$

其中

$$f(z_i^{(l+1)}) = f(\sum w_{ij}^{(l)} a_j^{(l)} + b^{(l)}) \quad (1-4)$$

假设神经网络的输出层看作网络的第 $l+1$ 层， y 是输入样本 x 的真实标签， $f()$ 是激活函数。之后我们便可以损失函数 J 求第 l 层到输出层的参数集 $(W^{(l)}, b^{(l)})$ 的梯度：

$$\frac{\partial J}{\partial w_{ij}^{(l)}} = \frac{\partial J}{\partial z_i^{(l+1)}} \frac{\partial z_i^{(l+1)}}{\partial w_{ij}^{(l)}} = \delta^{(l+1)} \frac{\partial z_i^{(l+1)}}{\partial w_{ij}^{(l)}} \quad (1-5)$$

$$= \delta^{(l+1)} \frac{\partial \sum w_{ij}^{(l)} a_j^{(l)} + b^{(l)}}{\partial w_{ij}^{(l)}} \quad (1-6)$$

$$= \delta^{(l+1)} a_j^{(l)} \quad (1-7)$$

同理有：

$$\delta_i^{(l+1)} = \frac{\partial J}{\partial z_i^{(l+1)}} \quad (1-8)$$

$$= \frac{\partial \frac{1}{2} \|y - f(z_i^{(l+1)})\|^2}{\partial z_i^{(l+1)}} \quad (1-9)$$

$$= -(y - f(z_i^{(l+1)})) f'(z_i^{(l+1)}) \quad (1-10)$$

如果 $f()$ 是sigmoid激活函数，那么有：

$$f'(z_i^{(l+1)}) = f(z_i^{(l+1)}) [1 - f(z_i^{(l+1)})] \quad (1-11)$$

根据导数的链式法则，我们可以得到递推公式：

$$\frac{\partial J}{\partial w_{ij}^{(l-1)}} = \frac{\partial J}{\partial z_i^{(l+1)}} \frac{\partial z_i^{(l+1)}}{\partial z_k^{(l)}} \frac{\partial z_k^{(l)}}{\partial w_{kj}^{(l-1)}} \quad (1-12)$$

$$= \delta_i^{(l+1)} \frac{\partial z_i^{(l+1)}}{\partial z_k^{(l)}} \frac{\partial z_k^{(l)}}{\partial w_{kj}^{(l-1)}} \quad (1-13)$$

$$= \delta_i^{(l+1)} \frac{\partial \sum w_{ij}^{(l)} a_j^{(l)} + b^{(l)}}{\partial z_k^{(l)}} \frac{\partial z_k^{(l)}}{\partial w_{kj}^{(l-1)}} \quad (1-14)$$

$$= \delta_i^{(l+1)} \frac{\partial \sum w_{ik}^{(l)} f(z_k^{(l)}) + b^{(l)}}{\partial z_k^{(l)}} \frac{\partial z_k^{(l)}}{\partial w_{kj}^{(l-1)}} \quad (1-15)$$

$$= (\sum w_{ik}^{(l)} \delta_i^{(l+1)}) f'(z_k^{(l)}) \frac{\partial z_k^{(l)}}{\partial w_{kj}^{(l-1)}} \quad (1-16)$$

$$= (\sum w_{ik}^{(l)} \delta_i^{(l+1)}) f'(z_k^{(l)}) a_j^{(l-1)} \quad (1-17)$$

$$= \delta_i^{(l-1)} a_j^{(l-1)} \quad (1-18)$$

用这个公式一路递推过去便可以求得每一层的梯度，之后利用更新公式便可以不停地更新参数：

$$w_{ij}^{(l)} = w_{ij}^{(l)} - \alpha \frac{\partial J}{\partial w_{ij}^{(l)}} \quad (1-19)$$

$$b^{(l)} = b^{(l)} - \alpha \frac{\partial J}{\partial b^{(l)}} \quad (1-20)$$

其中 α 表示学习率，属于人工设定的参数，来控制学习的步长。通过多次迭代训练，网络将会收敛到一个最优值，这就是神经网络的数学原理。

1.2 神经网络的瓶颈

基于神经网络的数学原理，其存在一些固有的缺点。

(1) 梯度越来越稀疏。上一节已经介绍了神经网络的BP算法，根据链式法则可以逐层推导出每一层神经网络的梯度。前一层的网络梯度是后一层的网络梯度乘以当前层的梯度，这就造成了梯度值变得越来越稀疏，最后出现梯度消失的问题。更加糟糕的是如果每一层的梯度大于1，那么将会使得梯度变得越来越大，产生梯度爆炸的问题。梯度爆炸的网络是不收敛的，而一个可以训练的网络通常都存在梯度消失的问题。梯度消失也限制了神经网络的层数，从而限制了神经网络能够表达的泛化能力。

(2) 参数量与计算量巨大。传统的神经网络采用全连接的方法。假设两层分别有 m 和 n 个神经元，在不考虑偏置参数 b 的情况下，共需要 $m \times n$ 个权重参数 w 。而且这种增

长随着层数的增加急剧增加，同时计算量也类似特性。计算机能实现的参数量和计算量是有限，这也使得神经网络的层数收到了限制，即网络的泛化能力收到了约束。

(3) 通常需要手动提取特征。因为传统神经网络的层数和参数量受到了限制，所以在使用神经网络的时候，通常我们不能直接将未处理的原始数据作为网络的输入。因此我们需要手动的对数据进行特征提取，把提取的特征向量作为网络的输入，来降低输入数据的维度。而手动提取特征是十分繁琐而不通用的，需要针对于具体任务设计特殊的特征提取方法。

当然神经网络还存在一些其他缺点，而卷积神经网络主要是解决了神经网络的缺点(2)、(3)。而(2)和(3)的解决同时也顺便减轻了(1)带来的影响。因此本文主要介绍以上所阐述的缺点。

2 卷积神经网络

卷积神经网络是深度学习的标志性成果，其前身是神经网络。2012年，Hinton团队首次利用卷积神经网络Alexnet获得ImageNet挑战赛的冠军，并大幅提高识别准确度^[2]。卷积神经网络主要是针对神经网络的缺点做了改进，总的概括起来为三个特性——局部连接、参数共享、池化采样。

2.1 局部连接

在传统的神经网络的图像分类问题中，如果我们要直接用原图像作为网络输入进行训练，那么每一个像素都要为之分配一个神经元。也就是说一个 1000×1000 像素的单通道灰度图像在输入层我们就需要 10^6 。如果下一层有100个神经元输出，那么参数量又要扩大一百倍。这样的网络如果最终要达到能够应用的程度，将会有巨大的参数量。

根据视觉神经相关研究的表明，我们的视觉神经元是有层次感。低层的视觉神经元更加关注具体的局部细节（例如边缘，纹理等），而高层视觉神经元更加关注高层特征等（例如轮廓、空间关系等）DBJR 低层神经元的实现就是通过局部连接的思想实现，因为低层的视觉特征只需要关注很小的一个区域（patch）的图像，而不需要关注整幅图像。这个被关注的区域就称为感受野，而实现方式就是通过局部连接。例如我们只关心一个 10×10 的区域，只需要100个参数就可以得到下一层神经元的输出。单独拿出来看，这

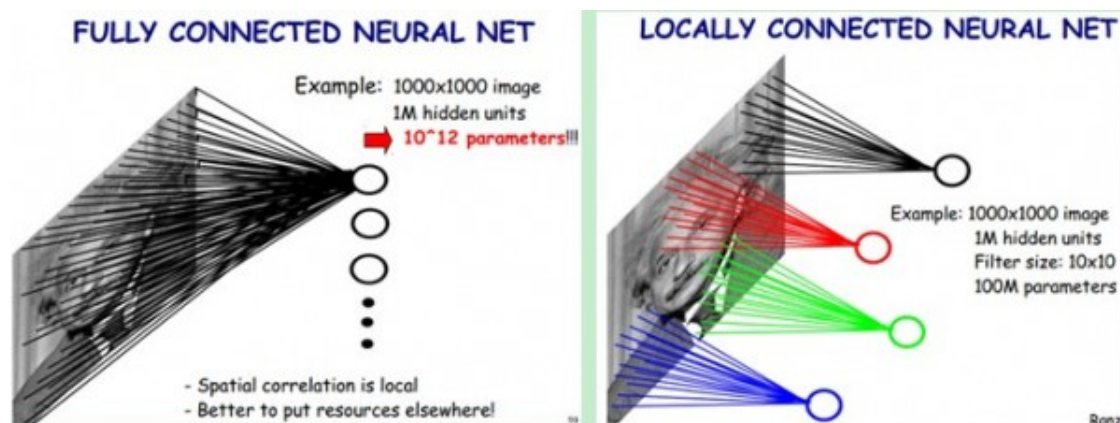


图 2-1 卷积神经网络的局部连接

就是一个 10×10 卷积核对图像中的这个patch做了一次卷积操作。从图2-1我们可以看到，输出的这个神经元的值只和这个patch有关，并没有用到整幅图像的值，这就是局部连接。

2.2 参数共享




图 2-2 卷积神经网络的权值共享

局部连接可以一定程度上减少参数量，但是参数量依然很大。上一小节提到卷积神经网络只关注感受野里的区域，然而一幅图像可以分割成许多这样的区域，每个区域都需要一个卷积核去卷积一遍。如果每个区域的卷积核都是不一样的，那么最后依然会有很多训练的参数，并且和传统的全连接也并没有太大的改进。

为了进一步减少网络模型的参数量，卷积神经网络的第二特性为参数共享。权值共享是指用一个卷积核去卷积一副图像里的所有patch。如图2-2所示，图像左边的部分有四个颜色方框，按照局部连接的思想，假如我们对四个patch进行卷积运算（图中四个颜色的框），理论上我们需要 $4 \times 10 \times 10$ 个参数量。如果对一幅图进行一次完整的循环卷积，那么参数量也是巨大的。所以我们可以把这个卷积核的参数固定，用一个固定的卷积核去对整幅图像进行卷积，这样参数量就是一个卷积核的参数量。权值共享不仅仅是直接的参数量大大缩小，它也是拥有充分论证的物理意义的，在图像处理领域一次卷积操作就是一次特征提取，例如边缘提取的Sobel算子等。

局部连接和参数共享合起来就是数学领域里的卷积计算，这也就是卷积神经网络的名字由来。一个卷积核只能提取一种特征得到一副特征图（feature map），所以卷积神经网络会设置若干个卷积核提取更多不同的特征图。之后网络会将这些特征图融合起来，融合的权重以及卷积核的参数都是网络自动学习出来的。

2.3 池化采样

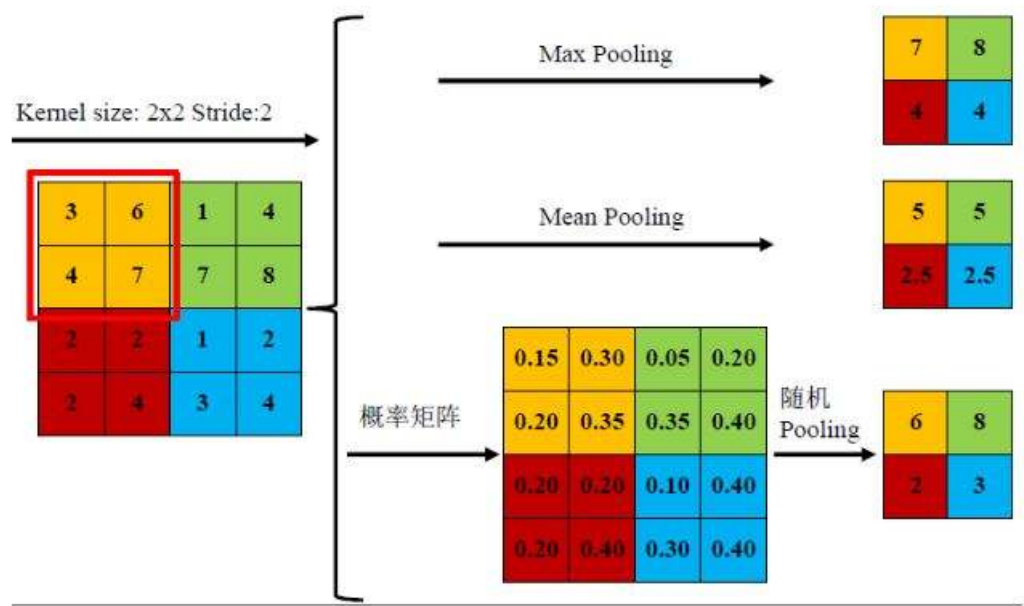


图 2-3 池化采样的常见的三种类型

局部连接和权值共享都把参数量大大减少，但是却没有改变感受野。并且如果用卷积之后的feature map去训练一个分类器，例如softmax 分类器，就需要特别大的计算量。例如：对于一个96 × 96像素的图像，假设我们已经学习得到了400个定义在8 × 8输入上的特征，每一个特征和图像卷积都会得到一个 $(96 - 8 + 1) \times (96 - 8 + 1) = 7921$ 维的卷积特征，由于有400个特征，所以每个样例(example)都会得到一个 $892 \times 400 = 3,168,400$ 维的卷积特征向量。学习一个拥有超过3 百万特征输入的分类器十分不便，并且容易出现过拟合(over-fitting)。

而池化采样是一个改变感受野并减少计算量的操作，使得网络可以实现多尺度多层次的特征提取。池化对不同位置的特征进行聚合统计。例如，人们可以计算图像一个区域上的某个特定特征的平均值(或最大值)。这些概要统计特征不仅具有低得多的维度(相比使用所有提取得到的特征)，同时还会改善结果(不容易过拟合)。池化通常分为平均池化(Mean pooling)、最大池化(Max pooling)和随机池化(Random pooling) (取决于计算池化的方法)。顾名思义，平均池化就是用一个区域的平均值代替该区域的特征，而最大池化采用的是该区域的最大值，如图2-3所示。随机池化相对麻烦一点，做法是先把区域中的值归一化为概率矩阵，然后根据这个概率分布随机挑选一个值作为下一层的feature，随机池化并不常使用。

接下来我们来了解下pooling操作，首先是为什么是max和mean。mean挺好理解的，我

们做事情通常喜欢用平均值来代替一个集合的性能。那么为什么是max而不是min了，这就要从神经网络的工作原理来理解，神经网络某个神经元的值特别大的话，说明这个神经元代表的属性被激活。浅层的可以是直线纹理等特征，高层的可以代表猫狗之类的特征，我们需要把这些被激活的特征属性给传下，所以用的是max而不是min。另外一个理解就是为什么需要pooling，前面提到pooling可以改变感受野大小。这里假设每次都是 2×2 大小的pooling，每做一次pooling之后feature map大小就变为了之前的一半，那么第二层做pooling的时候就用到了原始图片 4×4 大小patch的信息。越高层关注的区域就越大，也就是说感受野在逐渐变大。浅层关注的是局部的细节特征，高层关注的是更加广阔的全局（实际上是更大的局部）特征，pooling把CNN的提取特征的层次感给体现了。

3 卷积神经网络进行图像识别

3.1 卷积神经网络的优点

卷积神经网络是改进传统神经网络而来，所以其优点基本就是传统神经网络的缺点，概括如下：

(1) 卷积神经网络大大降低了网络的参数量和计算量，使得网络可以将原始未处理的（图像）直接作为网络输入，不再需要进行经验性的人工提取特征；

(2) 卷积神经网络可以提取不同尺度上的图像特征，更符合人类识别物体的客观规律，增加模型的识别准确度；

(3) 卷积神经网络可以监督信号自动学出最优的特征表达，这个特征表达通常比人工选择的更好，并且工作量大大减少；

(4) 卷积神经网络能够容纳的训练数据量比传统神经网络大的多，从而能学出更好的特征表达。

3.2 卷积神经网络识别图像实例

图3-1显示了CNN进行字符识别的示例，该网络输入图像为 32×32 ，共有2个卷积层、2个池化采样层和3个全连接层。第一个卷积层有6个卷积核，第三层卷积核有16个卷积核，两个卷积层的卷积核大小都是 5×5 ，并且后面都接了一个 2×2 的池化采样层。经过池化采




图 3-1 卷积神经网络字符识别实例

样，feature maps的大小缩小为一半，而下一层卷积层的感受野增加一倍。之后通过三个全连接层得到10 分类的输出层。

可以看出，前面卷积核关注的是比较小区域能的细节特征，而高层更加关注全局的轮廓信息。而最后一层的feature maps在经过一系列操作之后尺寸只有 $16 \times 5 \times 5 = 400$ ，但是却有16种图像特征。最有全连接输出一个10维的向量，每一个神经元代表一种类别。这种卷积神经网络图像识别的大致过程。

参考文献

- [1] Robert Hecht-Nielsen. Theory of the backpropagation neural network[C]//International Joint Conference on Neural Networks. 2002:593–605 vol.1.
- [2] Alex Krizhevsky, Ilya Sutskever, Geoffrey E. Hinton. Imagenet classification with deep convolutional neural networks[C]//International Conference on Neural Information Processing Systems. 2012:1097–1105.